

# 不确定性知识的表示与推理

## 第十三章 不确定性的量化

# 提纲

---

- **第十三章 不确定性的量化**
  - **13.1 不确定性的概述**
  - 13.2 不确定性与理性决策
  - 13.3 基本概率符号
  - 13.4 使用完全联合分布进行推理
  - 13.5 贝叶斯规则及其应用

# 不确定性

一个不确定性的例子：自动驾驶出租车智能体

**目标：**将乘客按时送到机场

**规划：** $A_t$  = 在飞机起飞 $t$ 分钟前出发，并以合理的速度驶向机场。

**问题：** $A_t$  规划能使乘客准时到达机场吗？

**环境：**

1. 部分可观测的 (路况, 其它驾驶员规划, etc.)
2. 不确定性(车辆爆胎, 引擎失灵, etc.)

# 不确定性

一个逻辑智能体可能给出的结论：

1. 有风险的断言：“规划 $A_{g_0}$  将使我们及时到达机场”
2. 得出如下的弱一些的结论：

“规划 $A_{g_0}$  将使我们及时到达机场，只要车不抛锚，汽油不耗尽，不遇到任何交通事故，桥上也没有交通事故，飞机不会提前起飞，而且没有陨星砸到我的车，……”

# 不确定性

一个不确定性推理的例子: 诊断牙病患者的牙痛

我们试着用**命题逻辑**写出牙病诊断的规则, 考虑下面的简单规则:

$Toothache \Rightarrow Cavity$  ✗

更新规则:

$Toothache \Rightarrow Cavity \vee GumProblem \vee Abscess \dots$

不幸的是: 为了使规则正确, 我们不得不增加一个无限长的可能原因的列表

# 不确定性

---

- 试图使用逻辑会失败，有以下三个原因：
  - 惰性: 无法列举出前提和结论的完整集合.
  - 无知: 缺乏相关事实、初始条件, etc.
    - 理论的无知: 对于该领域，缺少完整的理论.
    - 实践的无知: 即使我们知道所有的规则, 对于一个特定的病人我们也无法确定。

# 提纲

---

- **第十三章 不确定性的量化**
  - 13.1 不确定性的概述
  - **13.2 不确定性与理性决策**
  - 13.3 基本概率符号
  - 13.4 使用完全联合分布进行推理
  - 13.5 贝叶斯规则及其应用

# 处理不确定性的方法

- 不确定环境下，智能体的知识提供相关语句的**信念度**(degree of belief)，  
处理信念度的主要工具是**概率理论**(probability theory )
- 概率提供了一种方法以概括由我们的惰性和无知产生的不确定性
  - **规划 $A_{25}$  将使我们及时到达机场**的概率(可能性)是0.04
  - **牙痛病人有牙洞**的概率(可能性)是0.8



# 处理不确定性的方法

- 概率理论:

- 没有关于世界的断言
- 概率将命题与智能体自身的知识状态联系起来:

e.g.,  $P(A_{25} \mid \text{no reported accidents}) = 0.06$

- 命题的概率随新证据而变化:

e.g.,  $P(A_{25} \mid \text{no reported accidents, 5 a.m.}) = 0.15$

# 不确定性与理性决策

- 再次考虑去机场的规划  $A_t$

$$P(A_{25} \text{ gets me there on time} \mid \dots) = 0.04$$

$$P(A_{90} \text{ gets me there on time} \mid \dots) = 0.70$$

$$P(A_{120} \text{ gets me there on time} \mid \dots) = 0.95$$

$$P(A_{1440} \text{ gets me there on time} \mid \dots) = 0.9999$$

我们该如何做选择？

- 效用理论(Utility theory) 对偏好进行表示和推理，每个状态具有“效用”度量值

- 偏好: 及时到达机场、避免在机场长时间等待、避免路上超速罚单等

# 不确定性与理性决策

- 概率论：用于处理信念度的理论
- 效用理论：对偏好进行表示和推理，是有效性的度量
- 决策理论 = 概率理论 + 效用理论
  - 基本思想：一个智能体是理性的，当且仅当它选择能产生最高期望效用 (Maximum Expected Utility, MEU) 的行动
    - 期望效用是行动的所有可能结果的平均

# 不确定性与理性决策

```
function DT-AGENT(percept) returns an action  
  persistent: belief_state, probabilistic beliefs about the current state of the world  
               action, the agent's action  
  
  update belief_state based on action and percept  
  calculate outcome probabilities for actions,  
    given action descriptions and current belief_state  
  select action with highest expected utility  
    given probabilities of outcomes and utility information  
  return action
```

**Figure 13.1** A decision-theoretic agent that selects rational actions.

# 提纲

---

- **第十三章 不确定性的量化**
  - 13.1 不确定性的概述
  - 13.2 不确定性与理性决策
  - **13.3 基本概率符号**
  - 13.4 使用完全联合分布进行推理
  - 13.5 贝叶斯规则及其应用

# 基本概率符号

---

- 概率理论

- 随机变量、事件
- 概率公理
- 无条件概率（先验概率）、条件概率（后验概率）
- 完全联合概率分布
- 乘法法则、链式法则

# 随机变量

- 随机变量 表示可能世界中的不确定性
  - R (Is it raining?)
- 与命题逻辑相似：
  - 可能世界是由对随机变量的赋值进行定义的，随机变量以大写字母开头
- 布尔随机变量
  - e.g., *Cavity* (do I have a cavity?) 定义域:  $\langle \text{true}, \text{false} \rangle$
- 离散随机变量
  - e.g., *Weather* is one of  $\langle \text{sunny}, \text{rainy}, \text{cloudy}, \text{snow} \rangle$  变量的值总是用小写

# 随机变量

- 基本要素：随机变量
- 基本命题通过单个随机变量的赋值进行构造：
  - e.g., *Cavity = false* (abbreviated as  $\neg$ *cavity*)
  - *Weather = sunny* (abbreviated as *sunny*)
- 复合命题由基本命题的逻辑连接构造
  - e.g., *Weather = sunny*  $\vee$  *Cavity = false*



# 概率分布

考虑随机变量 *Weather*, 其定义域为 *<unny, rainy, cloudy, snow>*, 每个可能取值的概率, 可以写成:

$$P(\textit{Weather} = \textit{sunny}) = 0.6$$

$$P(\textit{Weather} = \textit{rain}) = 0.1$$

$$P(\textit{Weather} = \textit{cloudy}) = 0.29$$

$$P(\textit{Weather} = \textit{snow}) = 0.01$$

也可以简写为:


$$\mathbf{P}(\textit{Weather}) = \langle 0.6, 0.1, 0.29, 0.01 \rangle$$

(normalized, i.e., sums to 1)

**P**定义了随机变量 *Weather* 的一个概率分布

# 概率公理

- 对给定的两个随机变量  $A, B$ 
  - $0 \leq P(a) \leq 1$
  - $P(true) = 1$  and  $P(false) = 0$
  - $P(\neg a) = 1 - P(a)$
  - **$P(A \vee B) = P(A) + P(B) - P(A \wedge B)$**



# 先验概率

- 先验概率 或 无条件概率

e.g.,  $P(\text{Cavity} = \text{true}) = 0.1$

$P(\text{Weather} = \text{sunny}) = 0.72$

- 联合概率分布：多个变量取值的所有组合的概率

$P(\text{Weather}, \text{Cavity})$  是一个4\*2的概率表:

<i>Weather</i> =	sunny	rainy	cloudy	snow
<i>Cavity</i> = true	0.144	0.02	0.016	0.02
<i>Cavity</i> = false	0.576	0.08	0.064	0.08

- e.g.,  $P(\text{sunny}, \text{Cavity})$

- 完全联合概率分布：

- e.g.,  $P(\text{Toothache}, \text{Weather}, \text{Cavity})$

- 一个完全联合分布基本满足计算任何命题的概率的需求

# 条件概率

- 条件概率 或 后验概率
  - e.g.,  $P(\text{cavity} \mid \text{toothache}) = 0.8$
- 额外条件很重要
  - 如果获得进一步信息,  $\text{cavity}$ 为真, 条件概率将更新为:  
 $P(\text{cavity} \mid \text{toothache}, \text{cavity}) = 1$
- 无关的证据, 可以简化
  - e.g.,  $P(\text{cavity} \mid \text{toothache}, \text{sunny}) = P(\text{cavity} \mid \text{toothache}) = 0.8$
- 条件概率是由无条件概率定义的:

$$P(a|b) = \frac{P(a, b)}{P(b)} \quad \text{要求: } P(b) > 0$$

# 乘法法则和链式法则

- 乘法法则:

$$P(a \wedge b) = P(a \mid b) P(b) = P(b \mid a) P(a)$$

- e.g.,  $P(\text{Weather}, \text{Cavity}) = P(\text{Weather} \mid \text{Cavity}) P(\text{Cavity})$

- 考虑有n个变量的联合分布:

$$\begin{aligned} P(X_1, \dots, X_n) &= P(X_1, \dots, X_{n-1}) P(X_n \mid X_1, \dots, X_{n-1}) && \text{(乘法法则)} \\ &= P(X_1, \dots, X_{n-2}) P(X_{n-1} \mid X_1, \dots, X_{n-2}) P(X_n \mid X_1, \dots, X_{n-1}) && \text{(乘法法则)} \\ &= \dots \\ &= \prod_{i=1}^n P(X_i \mid X_1, \dots, X_{i-1}) && \text{(乘法法则)} \end{aligned}$$

- 链式法则:  $P(X_1, \dots, X_n) = \prod_{i=1}^n P(X_i \mid X_1, \dots, X_{i-1})$

# 提纲

---

- **第十三章 不确定性的量化**
  - 13.1 不确定性的概述
  - 13.2 不确定性与理性决策
  - 13.3 基本概率符号
  - **13.4 使用完全联合分布进行推理**
  - 13.5 贝叶斯规则及其应用

# 概率推理

- 使用完全联合概率分布作为“知识库”，从中可以导出所有问题的答案。
- 概率推理: 根据已观察到的证据，计算查询命题的后验概率。
- 例如，计算条件概率
  - $P(A_{100} \text{ on time} \mid \text{no reported accidents}) = 0.90$
  - 表示给定证据下的信念度
- 随着新的证据的出现，概率会发生变化
  - $P(A_{100} \text{ on time} \mid \text{no accidents, 5 a.m.}) = 0.95$
  - $P(A_{100} \text{ on time} \mid \text{no accidents, 5 a.m., raining}) = 0.80$
  - 观察新的证据，更新信念度

# 概率推理

- 一个简单的例子: 诊断牙病患者的牙痛
  - 问题域: 由三个布尔变量 *Toothache*, *Cavity* 和 *Catch* 组成
  - *Catch* 表示由于牙医的钢探针不洁而导致的牙龈感染
  - 给定完全联合分布, 一个  $2 \times 2 \times 2$  的表格

	<i>toothache</i>		$\neg$ <i>toothache</i>	
	<i>catch</i>	$\neg$ <i>catch</i>	<i>catch</i>	$\neg$ <i>catch</i>
<i>cavity</i>	0.108	0.012	0.072	0.008
$\neg$ <i>cavity</i>	0.016	0.064	0.144	0.576

**Figure 13.3** A full joint distribution for the *Toothache*, *Cavity*, *Catch* world.



# 枚举推理

- 给定完全联合分布:

	<i>toothache</i>		$\neg$ <i>toothache</i>	
	<i>catch</i>	$\neg$ <i>catch</i>	<i>catch</i>	$\neg$ <i>catch</i>
<i>cavity</i>	0.108	0.012	0.072	0.008
$\neg$ <i>cavity</i>	0.016	0.064	0.144	0.576

**Figure 13.3** A full joint distribution for the *Toothache*, *Cavity*, *Catch* world.

- 对于任意命题 $\phi$ , 其概率是使得该命题成立的可能世界的概率之和:  $P(\phi) = \sum_{\omega: \omega \models \phi} P(\omega)$
- 一种计算任何命题概率的方法:
  - 识别命题为真的可能世界, 然后把它们的概率加起来
  - 例如:  $P(\text{cavity} \vee \text{toothache}) = 0.108 + 0.012 + 0.072 + 0.008 + 0.016 + 0.064 = 0.28$

# 枚举推理

- 给定完全联合分布:

	<i>toothache</i>		$\neg$ <i>toothache</i>	
	<i>catch</i>	$\neg$ <i>catch</i>	<i>catch</i>	$\neg$ <i>catch</i>
<i>cavity</i>	0.108	0.012	0.072	0.008
$\neg$ <i>cavity</i>	0.016	0.064	0.144	0.576

**Figure 13.3** A full joint distribution for the *Toothache*, *Cavity*, *Catch* world.

- 一个特别常见的任务: 提取某个变量的概率分布 (无条件概率/边缘概率)
- 边缘化规则, 或者称为求和消元:
  - $P(\text{toothache}) = 0.108 + 0.012 + 0.016 + 0.064 = 0.2$

# 枚举推理

- 给定完全联合分布:

	<i>toothache</i>		$\neg$ <i>toothache</i>	
	<i>catch</i>	$\neg$ <i>catch</i>	<i>catch</i>	$\neg$ <i>catch</i>
<i>cavity</i>	0.108	0.012	0.072	0.008
$\neg$ <i>cavity</i>	0.016	0.064	0.144	0.576

**Figure 13.3** A full joint distribution for the *Toothache*, *Cavity*, *Catch* world.

- 条件概率是由无条件概率定义的, 可以计算条件概率:

$$\begin{aligned} P(\neg \text{cavity} \mid \text{toothache}) &= \frac{P(\neg \text{cavity} \wedge \text{toothache})}{P(\text{toothache})} \\ &= \frac{0.016 + 0.064}{0.108 + 0.012 + 0.016 + 0.064} \\ &= 0.4 \end{aligned}$$

# 枚举推理

$$\begin{aligned}P(\neg cavity \mid toothache) &= \frac{P(\neg cavity \wedge toothache)}{P(toothache)} \\&= \frac{0.016 + 0.064}{0.108 + 0.012 + 0.016 + 0.064} \\&= 0.4\end{aligned}$$

这两个计算出来的值相加等于1。

$$\begin{aligned}P(cavity \mid toothache) &= \frac{P(cavity \wedge toothache)}{P(toothache)} \\&= \frac{0.108 + 0.012}{0.108 + 0.012 + 0.016 + 0.064} \\&= 0.6\end{aligned}$$

分母是不变的，是常数。

# 枚举推理

■ 例如:  $P(\text{Cavity} \mid \text{toothache})$

$$= \alpha P(\text{Cavity}, \text{toothache})$$

$$= \alpha [P(\text{Cavity}, \text{toothache}, \text{catch}) + P(\text{Cavity}, \text{toothache}, \neg \text{catch})]$$

$$= \alpha [<0.108, 0.016> + <0.012, 0.064>]$$

$$= \alpha <0.12, 0.08>$$

$$= <0.6, 0.4>$$

## 归一化方法

基本思想: 计算查询变量的概率分布, 可以固定证据变量 (evidence variables), 然后在隐变量 (hidden variables) 上求和并归一化

# 枚举推理

## 归一化方法:

假设查询变量为 $X$ ; 证据变量集合为  $E$ ,  $e$ 表示其观察值; 假设其余的未观测变量为 $Y$ 。

计算查询变量:

$$P(X \mid e) = \alpha P(X, e) = \alpha \sum_y P(X, e, y)$$

- **问题:** 规模扩展性不好

- 对于一个由 $n$ 个布尔变量所描述的问题域, 最坏情况下的时间复杂性 $O(2^n)$ , 空间复杂性  $O(2^n)$

# 提纲

---

- **第十三章 不确定性的量化**
  - 13.1 不确定性的概述
  - 13.2 不确定性与理性决策
  - 13.3 基本概率符号
  - 13.4 使用完全联合分布进行推理
  - **13.5 贝叶斯规则及其应用**

# 贝叶斯规则

- 根据乘法法则，联合分布可以表示为:

$$P(a, b) = P(a|b)P(b) \quad P(a, b) = P(b|a)P(a)$$

- 同时除以 $P(a)$ ，得到贝叶斯规则:

$$P(b|a) = \frac{P(a|b)P(b)}{P(a)}$$

- 是大多数进行概率推理的人工智能系统的基础
- 贝叶斯规则在实践中很有用:
  - 很多情况下，前三项有很好的估计，而需要计算第4项

That's my rule!





# 应用贝叶斯规则

- 简单示例: 医疗诊断
- 结果 $effect$ 看作是证据, 确定造成这一结果的未知因素 $cause$ , 贝叶斯规则:

$$P(cause|effect) = \frac{P(effect|cause)P(cause)}{P(effect)}$$

- 条件概率 $P(effect|cause)$  量化了因果方向上的关系
- 条件概率 $P(cause|effect)$  描述诊断方向上的关系
- 实际中, 经常有因果关系的条件概率, 而想得出诊断关系。

# 应用贝叶斯规则

- 简单实例: 医疗诊断

- 医生知道脑膜炎有70%的可能会引起病人脖子僵硬。医生还了解一些无条件的事实：病人患脑膜炎的先验概率为1/50,000, 而任何一个病人脖子僵硬的概率为 1%。问：脖子僵硬的病人患脑膜炎的概率？

- 令m表示“病人患有脑膜炎”的命题, s表示“病人脖子僵硬”的命题

- 则有：  $P(m) = 1/50000$      $P(s|m) = 0.7$      $P(s) = 0.01$

- $P(m|s) = \frac{P(s|m) * P(m)}{P(s)} = (0.7 * 1/50000) / 0.01 = 0.0014$

# 应用贝叶斯规则

- 简单实例: 医疗诊断

- 医生知道脑膜炎有70%的可能会引起病人脖子僵硬。医生还了解一些无条件的事实：病人脖子僵硬的先验概率为1/50,000, 而任何一个病人脖子僵硬的概率为 1%。
- 问题: 计算 $P(M|s)$ ?
- 归一化的方法:

$$\mathbf{P}(M|s) = \langle P(m|s), P(\neg m|s) \rangle$$

$$= \alpha \langle P(s|m)P(m), P(s|\neg m)P(\neg m) \rangle$$

# 应用贝叶斯规则

- 简单示例2: 明天要举行户外运动。近年来, 每年仅下雨5天 ( $5/365=0.014$ ) 。不幸的是, 天气预报员预测明天会下雨。当真的下雨时, 天气预报员准确地预测了90%的降雨。当不下雨时, 他错误地预测了10%的降雨。明天下雨和不下雨的可能性分别有多大?
- 令rain表示明天下雨的概率, predict表示预测明天下雨的概率
- 则有:
  - $P(rain) = 0.014$ ;  $P(\neg rain) = 0.986$  ;  $P(predict|rain)= 0.9$ ;  $P(predict|\neg rain) =0.1$
- 问题: 计算 $P(Rain|predict)$ ?

# 应用贝叶斯规则

- 简单示例2: 明天要举行户外运动。近年来, 每年仅下雨5天 ( $5/365=0.014$ ) 。不幸的是, 天气预报员预测明天会下雨。当真的下雨时, 天气预报员准确地预测了90%的降雨。当不下雨时, 他错误地预测了10%的降雨。明天下雨和不下雨的可能性分别有多大?

$$\begin{aligned} P(Rain | predict) &= < P(rain | predict), P(\neg rain | predict) > \\ &= \alpha < P(predict | rain) * P(rain), P(predict | \neg rain) * P(\neg rain) > \\ &= \alpha < 0.9 * 0.014, 0.1 * 0.986 > \\ &= < 0.111, 0.889 > \end{aligned}$$

# 小结

---

- 由于环境可能是部分可观察的或不确定的，智能体需要处理不确定性。
- 概率是描述不确定知识的一种严格形式。通过条件概率，将命题与智能体自身的知识联系起来
- 给定一个完全联合分布可以计算该问题域中任何命题的概率，但对复杂领域，需要找到一种方法来降低联合概率的数目

# 作业

---

- 13.8
- 13.15